

De l'image au texte cherchable : traitement computationnel des télégrammes de Vichy (1940-1945)

Vincent Martin-Schreiber¹ , Florian Mathieu² , et Jasmin Macarios¹ 

¹ Université d'Ottawa, Canada

¹ Université Paris-Saclay, Orsay, France

Abstract

Cet article présente une chaîne de traitement complet pour la numérisation et la mise en accès d'environ 11 000 télégrammes diplomatiques du régime de Vichy interceptés par l'*Examination Unit* canadienne (1941–1945). En combinant reconnaissance optique de caractères par intelligence artificielle (Mistral OCR), extraction automatisée de métadonnées et diffusion en science ouverte via une plateforme Omeka, le projet transforme un corpus archivistique inaccessible en ressource cherchable et réutilisable. Les télégrammes sont désormais librement accessibles, permettant aux chercheurs d'interroger l'ensemble du fonds par recherche plein texte et requêtes booléennes. La contribution examine également les arbitrages techniques, environnementaux et épistémologiques que soulève l'application de méthodes computationnelles aux archives patrimoniales.

Mots-clés: humanités numériques, reconnaissance optique de caractères, archives diplomatiques, science ouverte, soutenabilité computationnelle

Keywords: digital humanities, optical character recognition, diplomatic archives, open science, computational sustainability

1 Introduction et corpus historique

La numérisation massive des archives patrimoniales depuis deux décennies a considérablement amélioré l'accessibilité physique des fonds documentaires. Toutefois, les formats de diffusion privilégiés – images de microfilms, PDF non interrogeables – créent un paradoxe : ces archives numériques demeurent largement inexploitable pour la recherche, notamment computationnelle [6]. Ainsi, l'absence de texte cherchable limite drastiquement les possibilités d'analyse à grande échelle, perpétuant une dépendance à la consultation manuelle exhaustive.

Ce projet aborde cette tension à travers le cas des télégrammes diplomatiques du régime de Vichy interceptés par l'*Examination Unit* canadienne. Ces 13 848 pages, conservées par Bibliothèque et Archives Canada sur cinq bobines de microfilm (T-17425 à T-17429) [4], constituent un corpus historique de premier ordre pour comprendre les coulisses de la diplomatie française pendant la Seconde Guerre mondiale. Le corpus couvre la période de 1941 à 1945. Les communications vichystes s'étendent de septembre 1941 à mars 1945, tandis que celles de la France libre couvrent la période de mars 1943 à juillet 1945 — créant une période de chevauchement d'environ deux ans (avril 1943 – mars 1945) durant laquelle les deux gouvernements sont simultanément représentés dans le fonds. Cette superposition documentaire confère au corpus une valeur analytique rare : il permet d'observer, dans un fonds homogène, la coexistence puis la substitution progressive des réseaux diplomatiques français à l'un des moments charnières du xx^e siècle.

Vincent Martin-Schreiber, Florian Mathieu, et Jasmin Macarios. "De l'image au texte cherchable: traitement computationnel des télégrammes de Vichy (1940-1945)." *Actes de la Conférence Humanistica*, éd. par Serena Crespi, Simon Gabay, Martin Grandjean, Ariane Pinche, Marie Puren et Léa Saint-Raymond. Vol. 4. Anthology of Computers and the Humanities. 2026, 220–226. <https://doi.org/10.63744/cvrm6IMHh1i9>.

© 2026 par les auteurs. Sous licence Creative Commons Attribution 4.0 International (CC BY 4.0).

L'*Examination Unit*, créée en juin 1941 sous l'administration du National Research Council, représente le premier bureau cryptographique civil canadien [11]. Sa mission consistait à intercepter et déchiffrer les communications diplomatiques étrangères, ciblant notamment les communications françaises – tant celles du régime de Vichy que celles des Forces françaises libres [5 ; 7]. Les documents produits, classifiés SECRET à l'époque, ont été progressivement déclassifiés depuis les années 1990 et sont aujourd'hui dans le domaine public. Ses images sont accessibles via le portail Canadiana Héritage à une résolution de 250 DPI selon le protocole IIIF [3]. Un exemple d'image est reproduit en Figure 1.

Malgré cette accessibilité physique, l'absence de transcription ou de métadonnées structurées rend le corpus difficilement exploitable pour des recherches ciblées ou pour l'utilisation de méthodes d'analyse computationnelle. Ce verrou limite concrètement plusieurs lignes de recherche historique dont la faisabilité dépend directement de la cherchabilité du fonds, par exemple :

Analyse des réseaux diplomatiques : la quantification et la cartographie des flux de communication entre les principaux postes consulaires (Washington, Ottawa, Alger, Buenos Aires, Madrid, etc.) et leur évolution au fil du conflit permettraient de reconstruire la géographie relationnelle de la diplomatie vichyste, impossible à établir par lecture manuelle sur un corpus de cette échelle en complément des connaissances déjà construites.

La rupture Vichy / France libre : la transition d'octobre 1944 inscrite dans ce même fonds offre une opportunité comparative pour analyser les continuités et ruptures dans les pratiques diplomatiques, les réseaux de personnes et les thématiques entre les deux régimes.

Recherche thématique ouverte : un chercheur souhaitant étudier, par exemple, la marine française et son implantation dans les colonies des Antilles pendant le conflit peut, grâce à la cherchabilité du corpus, identifier instantanément l'ensemble des télégrammes pertinents par des requêtes booléennes — une capacité fondamentale pour tout travail monographique ou thématique s'appuyant entre autres sur ce fonds.

Notre contribution présente la chaîne de traitement complet développé pour lever ce verrou, en documentant ses résultats, ses limites et les questions de soutenabilité qu'il soulève.

2 Méthode : chaîne de traitement automatisée en cinq phases

Notre approche repose sur un flux de production reproductible schématisé sur la Figure 2. Elle articule quatre phases distinctes, privilégiant l'automatisation maximale, la documentation rigoureuse et l'utilisation de formats ouverts. Les phases 1 et 2 du diagramme se sont pas listée ici, car les télégrammes étaient déjà numérisés et accessibles, et les images ont été téléchargées. Le développement et le traitement complet du corpus se sont étendus sur trois mois, combinant développement logiciel (Python 3.8+) et traitement à grande échelle.




FIGURE 1 – Image 2885 de la bobine T17428 (Canada Department of National Defence).




FIGURE 2 – Flux de production du projet des images jusqu’à la mise à disposition.

Phase 3 — OCR par intelligence artificielle. Les documents présentent des défis techniques : frappe mécanique des années 1940 dégradée par plusieurs générations de microfilmage, mélange de français et d’anglais, abréviations diplomatiques non standardisées et annotations manuscrites marginales. Le choix s’est porté sur Mistral AI (modèle *mistral-ocr-2512*) [10], un modèle multi-modal optimisé notamment pour les documents historiques typewrités, dont les performances sur ce type de corpus se sont révélées adaptées à nos contraintes (voir la Figure 1 et sa transcription *infra*). Le traitement complet a été effectué via l’API REST de Mistral OCR¹ avec un système de traitement parallèle (cinq requêtes simultanées) et gestion automatique des erreurs, pour une durée totale d’environ quinze heures. Les résultats ont été stockés en deux formats complémentaires : fichiers TXT pour l’interopérabilité et fichiers JSON incluant les métadonnées techniques complètes.

Phase 4 — Extraction de métadonnées structurées. Une chaîne de traitement automatisée développée en Python transforme le texte brut en métadonnées structurées exploitables. Le système détecte automatiquement les frontières documentaires puis extrait les champs essentiels : émetteurs, destinataires, dates d’envoi et de réception, numéros de messages et signatures. Les techniques employées combinent des expressions régulières optimisées, du *fuzzy matching* utilisant la distance de Levenshtein pour gérer les variations orthographiques, et une base de données géographiques recensant plus de 150 lieux diplomatiques. Les résultats quantitatifs démontrent l’efficacité de l’approche : environ 85% des dates ont été correctement extraites et normalisées au format ISO 8601².

Phase 5 — Reconnaissance d’entités nommées. Un module de *Named Entity Recognition* (NER) enrichit automatiquement le corpus par l’extraction d’entités géographiques (villes, pays) et de personnels diplomatiques. Cette couche d’annotation constitue le socle technique des analyses

1. <https://docs.mistral.ai/api/endpoint/ocr>.

2. Ce nombre est une estimation temporaire, l’analyse étant encore en cours à la date de publication de cet article.

de réseaux planifiées.

Diffusion et préservation. La collection est publiquement accessible via une plateforme Omeka hébergée à l'Université d'Ottawa³. L'interface offre une recherche plein texte sur l'ensemble du corpus, des filtres par métadonnées et un accès aux images originales via protocole IIIF. Des dépôts pérennes sur Zenodo ont été créés et seront mis à jour au fil de l'évolution du projet. Ils incluent l'attribution d'un DOI et l'attribution d'une licence CC BY-SA 4.0⁴.

From: Buenos Aires

To: Vichy

Dated: Nov.~28, 1942

Rec'd: Nov.~30, 1942

830

Le sabordage de la flotte française par les équipages a provoqué hier soir une émotion particulière dans la population de Buenos Aires.

Ce matin, les journaux rendent un hommage unanime à l'héroïsme de nos marins; par de tels sacrifices, écrivent-ils, la France immortalisera les épreuves (effroyables) qui se sont (abattues) sur elle.

Le comité France-Amérique organisera au début de la semaine prochaine un service religieux pour les marins morts à Toulon.

LATOURNELLE

R-3559-9

From: Buenos Aires To: Vichy Dated: Nov.~28, 1942 Rec'd: Nov.~30, 1942

832 Votre tél. 665K.

M. EUGENE COLSON inconnu en Argentine.

x-D-3464 LATOURNELLE

R-3561

File D-3502 Examination Unit, National Research Council December 1, 1942

FIGURE 3 – Transcription brute après OCR de l'image du télégramme de la Figure 1.

3 Résultats : un corpus structuré et accessible

La chaîne de traitement a transformé les 13 848 pages en un corpus numérique structuré et interrogeable. L'extraction automatisée est en cours de finalisation et a permis d'identifier environ 11 000 télégrammes distincts. Les métriques d'extraction temporaires reflètent à la fois l'efficacité de la chaîne de traitement et les défis propres à ce type de documents : 75% de réussite pour l'extraction des dates d'envoi, 51% pour les numéros de messages et 86% des postes émetteurs et récepteurs. Ces performances restent confrontées à plusieurs défis documentés : fragmentation des métadonnées sur les documents multipages, variations orthographiques des noms de lieux, et ambiguïtés entre dates d'envoi, de réception et de décodage.

La valeur concrète du corpus cherchable se mesure directement à travers des cas d'usage. Par exemple, un chercheur souhaitant étudier la marine française et son implantation aux Antilles pendant le conflit peut, via l'interface Omeka, interroger l'intégralité du corpus par requêtes booléennes et identifier instantanément les documents pertinents – une opération qui aurait nécessité la

3. <https://omeka.uottawa.ca/examination-unit>.

4. Les dépôts du projet sont disponibles dans la communauté Zenodo créée spécifiquement à l'URL : <https://zenodo.org/communities/examination-unit> et le code du projet est sur la plateforme GitLab : <https://gitlab.com/untracked7957/examination-unit>.

lecture exhaustive de milliers de pages dans le format image original⁵. Cette capacité de recherche thématique ouverte constitue la contribution opérationnelle centrale du projet pour la communauté des historiens.

La transparence constitue un principe directeur : les erreurs connues sont explicitement signalées, les images originales demeurent accessibles pour vérification, et les données sont exportables aux formats CSV et JSON pour réutilisation computationnelle. L'accès est gratuit et sans inscription, conformément aux principes de science ouverte.

4 Discussion : arbitrages techniques et questions de soutenabilité

La transformation de ce corpus confronte à un trilemme méthodologique dont les implications environnementales varient considérablement selon le scénario retenu. Le statu quo – maintenir uniquement les images haute résolution – présente un impact environnemental direct quasi nul, mais perpétue l'inaccessibilité computationnelle et rend impossibles les analyses historiques dont des exemples sont fournis plus haut. La transcription manuelle intégrale garantirait une haute qualité avec un impact environnemental estimé à 120–810 kWh, mais les 3 000–4 500 heures de travail humain nécessaires⁶ la rendent économiquement irréaliste sans financement majeur. L'OCR par intelligence artificielle, option retenue, combine environ 120 heures de travail humain avec un coût computationnel d'inférence GPU dont l'impact environnemental reste à quantifier précisément – une évaluation systématique (13 848 requêtes API, infrastructure GPU de Mistral AI) est en cours et fera l'objet d'une publication ultérieure incluant également une évaluation de l'impact social du projet.

Ce coût ponctuel peut notamment être justifié par une perspective de science ouverte : en rendant les données immédiatement disponibles et réutilisables sous licence CC BY-SA 4.0, nous évitons que d'autres chercheurs ne reproduisent ce traitement, amortissant ainsi l'empreinte environnementale initiale. Cette mitigation par mutualisation reste elle-même à quantifier : combien de chercheurs réutiliseront effectivement ces données, et sur quelle durée ? La science ouverte constitue une condition nécessaire, mais probablement insuffisante pour justifier l'usage de l'IA sans mesures d'impact précises.

Ce projet adopte donc une posture de documentation expérimentale plutôt que de validation d'une solution optimale. La question centrale demeure ouverte : dans quels contextes, à quelles conditions et à quel coût environnemental l'usage de l'intelligence artificielle devient-il défendable pour la transformation d'archives patrimoniales ? Ce corpus, par la singularité historique des sources qu'il rend accessibles, constitue un cas d'usage où l'enjeu scientifique semble suffisant pour engager sérieusement ce débat. Plus généralement, la question de l'impact environnemental de la numérisation d'un corpus donné invite également au dialogue avec les études menées à des échelles plus importantes telle qu'une unité de recherche [2], voire d'une discipline entière sur le plan international [9].

5 Perspectives

Le résultat immédiat du projet est un corpus de plus de 11 000 télégrammes diplomatiques désormais cherchables, structurés et librement accessibles – une ressource qui n'existait pas il y a 6 mois. Cette disponibilité constitue en elle-même la contribution centrale : tout chercheur travaillant sur

5. Exemple de requête permettant une recherche booléenne sur les Antilles : <https://omeka.uottawa.ca>.

6. Cette fourchette repose sur une vitesse de transcription manuelle soigneuse estimée entre 3 et 4,5 pages/heure pour ces documents dactylographiés. À 3 pages/heure (hypothèse conservatrice), 13 848 pages représentent environ 4 616 heures ; à 4,5 pages/heure (hypothèse optimiste), environ 3 077 heures. Sur le plan énergétique, la consommation directe du poste de travail a été estimée selon trois scénarios. Appliquée à la fourchette de 3 000–4 500 heures, cette hypothèse produit une plage de consommation électrique directe de 120 à 810 kWh.

la diplomatie française de la Seconde Guerre mondiale, sur le renseignement canadien, ou sur des thématiques connexes peut dès aujourd'hui interroger ce fonds selon ses propres questions de recherche, sans avoir à reproduire le traitement.

Des approches méthodologiques moins traditionnelles peuvent également être utilisées, comme par exemple l'analyse des réseaux diplomatiques tel que l'ont fait certains chercheurs par le passé [1 ; 8]. La perspective principale est donc moins de prescrire un programme analytique que de catalyser une communauté de chercheurs qui s'appropriera ces données et la plateforme selon des angles que le projet lui-même n'a pas anticipés.

L'amélioration continue du corpus repose sur une dimension collaborative structurée. La plateforme Omeka pourrait servir de support à une correction *crowdsourcée* de l'OCR, à la validation des métadonnées par des experts de l'histoire de Vichy, et à l'ajout d'annotations thématiques. Cette stratégie participative offre également une voie vers des arbitrages technologiques plus soutenables : l'expérience acquise suggère qu'une approche alternative privilégiant des modèles OCR *open source* sur CPU, dont les imperfections seraient progressivement compensées par la communauté, pourrait constituer un modèle plus équilibré pour des projets futurs similaires.

Références

- [1] BŁOCH, Agata, VASQUES FILHO, Demival et BOJANOWSKI, Michał. « Networks from Archives : Reconstructing Networks of Official Correspondence in the Early Modern Portuguese Empire ». In : *Social Networks* 69 (2022), p. 123-135. DOI : 10.1016/j.socnet.2020.08.008.
- [2] CNRS. « Empreinte Environnementale Du Numérique : Le CNRS Fait Les Comptes ». Avr. 2026. URL : <https://www.cnrs.fr/fr/actualite/empreinte-environnementale-du-numerique-le-cnrs-fait-les-comptes>.
- [3] DEPARTMENT OF NATIONAL DEFENCE. « Examination Unit (1939/1946) ». In : *Canadiana*. Ottawa : Réseau canadien de documentation pour la recherche, n.d. URL : <https://n2t.net/ark:/69429/s03n20c4tm4d>.
- [4] DEPARTMENT OF NATIONAL DEFENCE. *Examination Unit [Textual Record]*. Ottawa : Bibliothèque et Archives Canada, 1939/1946. URL : <https://central.bac-lac.gc.ca/.redirect?app=fonandcol&id=134683>.
- [5] EBERLEE, Sam. « Scholar, Diplomat, Intelligence Pioneer : Herbert Norman and Canada's Special Intelligence Section, 1942-1945 ». In : *Intelligence and National Security* 39, no. 5 (2024), p. 879-896. DOI : 10.1080/02684527.2023.2287801.
- [6] HAWKINS, Ashleigh. « Archives, Linked Data and the Digital Humanities : Increasing Access to Digitised and Born-Digital Archives via the Semantic Web ». In : *Archival Science* 22, no. 3 (2022), p. 319-344. DOI : 10.1007/s10502-021-09381-0.
- [7] JENSEN, Kurt F. *Cautious Beginnings : Canadian Foreign Intelligence, 1939-51*. Vancouver : UBC Press, 2008.
- [8] JO, Eun Seo. « Diplomatic History by Data : Understanding Cold War Foreign Policy Ideology Using Networks and NLP ». In : *Digital Humanities 2016*. Cracovie, Pologne, 2016. URL : <https://dh-abstracts.library.cmu.edu/works/2429>.
- [9] KNÖDLSIEDER, Jürgen, CORIAT, Mickael, GARNIER, Philippe et HUGHES, Annie. « Scenarios of Future Annual Carbon Footprints of Astronomical Research Infrastructures ». In : *Nature Astronomy* 8, no. 11 (2024), p. 1478-1486. DOI : 10.1038/s41550-024-02346-0.
- [10] MISTRAL AI. « Mistral OCR ». Avr. 2026. URL : <https://mistral.ai/news/mistral-ocr>.

- [11] WARK, Wesley K. « Cryptographic Innocence : The Origins of Signals Intelligence in Canada in the Second World War ». In : *Journal of Contemporary History* 22, no. 4 (1987), p. 639-665. URL : <https://www.jstor.org/stable/260814>.